

Supervivencia del cáncer de mama



The illustration features four diverse women of various ethnicities and ages, smiling and holding a glowing pink ribbon that contains various medical and scientific icons like a DNA helix, a brain, a heart, and a microscope. The background is a soft purple gradient with a subtle pattern of dots.

Estudio	Año	Supervivencia (%)
Estudio 01	2018	92.1
Estudio 02	2019	89.7
Estudio 03	2020	91.3
Estudio 04	2021	93.4
Estudio 05	2022	94.8
Estudio 06	2023	96.2

...

Maria Jose Hernandez Aguilar
2232999


Yerson Guillermo Antolinez Peña
2225611

John Anderson Sotelo Rueda
2224769

...

Introducción y Contexto

- El cáncer de mama es una de las principales causas de mortalidad femenina a nivel mundial
- El análisis de supervivencia estudia el tiempo desde un evento inicial (cirugía) hasta un evento de interés (fallecimiento o última visita)
- La IA permite extraer patrones predictivos a partir de registros clínicos estructurados
- Objetivo general del proyecto: predecir el comportamiento de supervivencia usando algoritmos de aprendizaje automático
- El proyecto pasó por dos enfoques: regresión primero y luego clasificación






La Materia Prima: Anatomía del Dataset



Entrada: 334 registros



Filtro: eliminación
de 35 filas con
nulos críticos
(fecha, estado).



Salida: 299 pacientes viables



Features clínicos

Edad, estadio tumoral (I, II, III), histología, estado de receptores (ER/PR/HER2) y tipo de cirugía.



Features biológicos

Niveles de 4 biomarcadores específicos: proteína 1 a proteína 4.



Variable objetivo derivada


$\text{Survival_Time} = \text{Date_of_Last_Visit} - \text{Date_of_Surgery}$



Idea clave

La cohorte final conserva solo casos con información suficiente para modelar supervivencia.

Curva de supervivencia






Pipeline de Preprocesamiento



1. Detección de Outliers (IQR)



Limpieza extrema en proteínas 2 y 3.

2. Manejo de faltantes



Purga estricta de registros sin fechas o estatus de supervivencia.

3. Codificación categórica



Mapeo binario: Alive=1, Dead=0; FEMALE=1; MALE=0; Positive=1; Negative=0.


4. Normalización escalar



Aplicación de StandardScaler para equilibrar magnitudes algorítmicas.



Fase 1: La Hipótesis de Regresión



Parámetros analíticos



Objetivo: mapear features directamente a la variable continua Survival_Time.



División: 80% entrenamiento (239 muestras) / 20% prueba (60 muestras).



Modelos evaluados



Decision Tree Regressor (max_depth)



Random Forest Regressor (n_estimators)



Support Vector Regression (kernel)


Resultados de Regresión: El Diagnóstico del Fracaso




Matriz de alertas

- $R^2 \approx 0$: ningún modelo fue estadísticamente mejor que adivinar el promedio del dataset.
- MAE ≈ 800 días: error absoluto medio cercano a 2 años por paciente. Clínicamente inaceptable.
- Fallo de Deep Learning: redes MLP sufrieron Dying ReLU y sobreajuste masivo sin convergencia en validación.

Predicción vs Realidad




¿Por qué falló la Regresión? Incompatibilidad Algorítmica




Señal débil

La matriz de correlación reveló que el impacto de proteínas y edad sobre los días exactos es marginal ($|r| < 0.15$).



Ruido alto

Survival_Time exhibió varianza extrema y caótica, oscilando impredeciblemente de pocos días hasta más de 2.000 días.



Datos escasos

$n=299$ es insuficiente para que modelos, especialmente Deep Learning, abstraigan relaciones funcionales sin sobreajuste severo.



El Pivote: De Días Inciertos a Categorías Clínicas



Regresión (Días)



Clase 0:
Baja supervivencia



0 a 24 meses



Umbral crítico
a corto plazo



Clase 1:
Supervivencia media



24 a 60 meses



Clase 2:
Alta supervivencia



> 60 meses



Remisión internacional
de 5 años



Insight metodológico: uso de **stratify=y** para asegurar el balance poblacional.



Fase 2: Modelos Clásicos de Clasificación



Decision Tree



Punto óptimo:
profundidad media (6-10).



Diagnóstico:
profundidad >12 sufre
overfitting severo.
Precisión Train alta,
pero se desploma en Test.



Random Forest (El campeón)



Punto óptimo:
100-200 árboles.



Diagnóstico:
mayor estabilidad general
y menor varianza sin
requerir cómputo masivo.



Support Vector Machine (SVM)




Punto óptimo:
kernel radial (RBF).



Diagnóstico:
kernel lineal pobre;
polinomial sobreajusta;
RBF genera excelentes
fronteras.



Validación Cruzada: Buscando la Estabilidad



El comportamiento de ensambles


A medida que el valor de k aumenta, la varianza de Random Forest se comprime y estabiliza la precisión promedio en una franja de 63-68%.

El fallo individual

El Decision Tree presenta una variabilidad errática en todas las particiones, descartándolo para un entorno clínico real.



Deep Learning en Clasificación: El Ensayo MLP



10 Epochs


Insuficiente. Underfitting evidente.

50 Epochs (El punto óptimo)

El modelo intermedio de 6 capas logra el mejor balance entre abstracción y generalización.

100 Epochs

Overfitting masivo. EarlyStopping interviene; redes muy profundas colapsan por falta de datos volumétricos.



La Matriz Final de Resultados



Modelo	Accuracy (validación)	Comportamiento	Veredicto
Decision Tree	60-65%	Rápido, interpretable, falla con alta complejidad.	Moderado
MLP intermedio	60-66%	Competitivo pero varianza alta por inicio aleatorio.	Aceptable
SVM (RBF)	62-67%	Excelentes fronteras curvilíneas; sensible a parámetros.	Alto potencial
Random Forest	63-68%	Extraordinaria robustez y mitigación de varianza empírica.	Campeón clínico



Anatomía del Error: La Matriz de Confusión



Clase 0	116	69	38
Clase 1 real	65	299	47
Clase 2	53	113	160
	Clase 0	Clase 1	Clase 2

Predicción

Lectura del error

El fuerte: la Clase 1 (supervivencia media) domina por completo la predicción. Al ser el perfil mayoritario en los 299 pacientes, los algoritmos se especializaron en ella.

La fricción: la Clase 2 (alta supervivencia) sufre falsos negativos masivos, confundiéndose con Clase 1 por similitudes clínicas difíciles de separar.

Diagnóstico final: el desbalance natural de clases afecta la capacidad predictiva en los extremos (alta y baja).



Conclusiones Analíticas: El Arte de Redefinir



1 Regresión vs. Clasificación

Intentar predecir un día exacto sin datos perfectos es fútil empíricamente. Agrupar la incertidumbre en umbrales de riesgo clínico genera herramientas accionables.

2 Complejidad vs. Densidad

El Deep Learning no es omnipotente. Con $n=299$, la navaja de Ockham prevalece: los ensambles estadísticos como Random Forest superan a redes profundas en estabilidad.

3 La limitación de origen

Los 4 biomarcadores y el perfil basal son señales insuficientes. La precisión del ~68% marca el límite matemático actual de este dataset clínico.



Próximos Pasos en el Horizonte Clínico



01 Equilibrio




Aplicar técnicas de oversampling (SMOTE) o pesos dinámicos para compensar la minoría de clases 0 y 2.



02 Volumen



Ampliar la cohorte clínica. Arquitecturas MLP necesitan miles de registros para superar a los árboles de decisión.



03 Nuevas variables



Incorporar predictores ausentes: IMC, estadio molecular y protocolo exacto de tratamiento.